이서연 · 이력서 / PROFILE

RAG 검색 품질 · 하이브리드 검색 · 근거 기반 평가 | RAG / LLM Evaluation Engineer

지원 요약

신입 AI 엔지니어 지원자. 검색된 근거와 모델 답변 사이의 일치 여부를 검증하는 RAG 평가 체계에 관심이 있습니다. 데이터셋 구성, 검색 실험, 에러 분석, 평가 대시보드까지 한 흐름으로 다뤄 본 프로젝트 경험이 있습니다.

기본 정보

이메일: seoyeon.lee@example.com | 거주: 경기 성남(가상) | 지원 분야: RAG / LLM Evaluation / AI 서비스
학력: 미래대학교 데이터사이언스학과 학사 (2026.02 졸업, 가상)
경험: 2025.03~08 대학 산학 프로젝트, 2025.09~2026.06 문서검색 QA 시스템 개발

핵심 역량

- 문서 파싱·청킹·임베딩·하이브리드 검색·재순위화·답변 생성 파이프라인
- Recall@k, MRR, nDCG 및 근거 충실도 기반 정량·정성 평가
- PostgreSQL + pgvector, BM25 검색, Python, pandas 기반 데이터 처리
- 실험 조건 관리, 오류 유형 분류, 데이터 누수와 출처 혼입 방지

대표 프로젝트

프로젝트 A | 사내 기술문서 RAG 검색 서비스 (2025.09~2026.06)

기술 문서와 장애 이력을 검색하는 QA 서비스. 4인 팀에서 문서 데이터 파이프라인, 검색 실험 및 평가셋 개발 담당.

프로젝트 B | 공공 문서 분류·요약 품질 점검 (2025.03~08)

PDF 형식과 길이가 제각각인 공공 문서의 분류 및 요약 오류를 측정한 산학 프로젝트. 데이터 정제와 라벨링 정책 수립 담당.

지원 동기

LLM 서비스가 좋은 답변을 생성하더라도 잘못된 근거를 사용하면 신뢰할 수 없다는 점에 주목합니다. 검색과 평가의 연결을 강화하는 개발자로 성장하고 싶습니다.

이서연 · 대표 프로젝트 / ARCHITECTURE

RAG 검색 품질 · 하이브리드 검색 · 근거 기반 평가 | RAG / LLM Evaluation Engineer

프로젝트 A 개요

여러 팀의 기술 가이드, 장애 후속 보고서, 개발 규칙이 PDF와 Markdown으로 흩어져 있어 질문에 맞는 문서를 찾기 어려웠습니다. 목표는 단순 의미검색이 아니라 최신 문서와 유효한 운영 기준을 우선하는 근거 기반 QA 서비스였습니다.

데이터 구성

- 가상 프로젝트 수집 문서 1,800건: Markdown 820, PDF 640, HTML 340
- 원본 문서 ID, 버전, 작성 조직, 갱신일, 접근 권한, 섹션 경로를 메타데이터로 관리
- 제목·표·본문을 구분해 문서 구조에 맞게 청킹하고 중복 섹션은 해시 기반 제거
- 문서 삭제·갱신 시 임베딩 색인의 동기화 상태를 검증하는 배치 작업

검색 구조

질문 정규화 → 권한·유효일 필터 → BM25/벡터 검색 → 결과 병합 → 재순위화 → 근거 중심 답변 생성 순서로 구성했습니다. 검색과 답변 생성은 따로 평가하여 어느 단계에서 실패했는지 구분했습니다.

담당 구현

1. 문서 파서 및 청크 품질 관리

목차와 표의 제목을 함께 보존하고, 문맥이 필요한 문단은 상위 섹션 제목을 메타데이터에 포함했습니다.

2. 검색 실험

키워드 검색과 임베딩 검색의 점수를 정규화해 결합하고, 후보 20개를 재순위화한 뒤 최종 5개를 생성 단계로 전달했습니다.

3. 실패 관측

검색 누락, 버전 오류, 권한 혼입, 답변 근거 불일치, 근거 부족 등을 별도 오류 코드로 저장했습니다.

이서연 · 문제 해결 / TECHNICAL DEPTH

RAG 검색 품질 · 하이브리드 검색 · 근거 기반 평가 | RAG / LLM Evaluation Engineer

평가셋 설계

팀원과 함께 240개 질의를 작성하고 각 질의에 정답 문서와 최소 근거 구간을 라벨링했습니다. 단순 키워드 질의, 문서 간 비교, 최신 버전 확인, 관련 문서 없음 상황을 고르게 포함했습니다.

평가 지표

검색: Recall@5, MRR@10, nDCG@10

생성: 근거 문장 일치 여부, 답변의 사실 충실도, 질문 관련성

운영: P50/P95 지연, 검색 실패율, 문서 갱신 후 색인 반영 지연

실험과 결과 (가상 프로젝트 측정값)

240개 질의를 고정 평가셋으로 사용한 결과, 벡터 단독 검색의 Recall@5는 0.71이었고 하이브리드 검색과 재순위화를 적용한 뒤 0.84로 개선되었습니다. 근거 누락 답변 비율은 17%→9%로 감소했습니다. 수치가 개선돼도 최신 문서 선택 실패가 남아 문서 유효일 필터를 강화했습니다.

가장 어려웠던 문제

최신 문서와 유사한 과거 문서가 동시에 검색됨

동일 문서의 개정판이 서로 높은 유사도를 갖는 문제가 있었습니다. 문서 계열 ID와 버전 정보로 최신판을 기본 선택하고, 과거판을 요청하는 질문에서는 필터를 해제하도록 수정했습니다.

답변 평가와 검색 평가가 섞임

검색 결과는 정확하지만 모델이 잘못 요약하는 사례가 있어 검색 단계와 생성 단계를 분리 평가했습니다. 이후 질의별 실패 원인을 추적하기 쉬워졌습니다.

이서연 · 협업 및 추가 경험 / EXPERIENCE

RAG 검색 품질 · 하이브리드 검색 · 근거 기반 평가 | RAG / LLM Evaluation Engineer

프로젝트 B | 공공 문서 분류·요약 검증

PDF 표와 각주 때문에 본문이 뒤섞인 문서를 처리하는 프로젝트였습니다. 추출된 텍스트만 신뢰하지 않고 페이지 번호·표 제목·문서 구조 정보를 함께 관리했습니다.

실무 문제와 해결

- 텍스트 추출 시 단락 순서가 뒤바뀌는 문서를 샘플링해 원본 페이지와 비교 검토
- 문서별 라벨링 가이드를 통일하고 애매한 사례는 검토자 합의로 처리
- 요약 답변에 수치가 들어가면 원문 표 셀 또는 문장 단위 출처를 확인하도록 검증 규칙 추가
- 민감한 정보가 포함된 예제 문서는 익명화한 뒤 실험 데이터에 반영

협업과 피드백

초기에는 높은 유사도 점수를 품질의 전부로 생각했으나 팀원 리뷰에서 권한 혼입 사례를 지적받았습니다. 이후 검색 정확도 외에 접근 범위와 문서 시점을 평가 항목으로 추가했습니다. 검색 품질은 숫자 하나로 설명하기 어렵다는 점을 배웠습니다.

학습 주제

임베딩 모델의 벡터 차원과 검색 성능의 관계, BM25와 벡터 검색의 상호 보완, Cross-Encoder 재순위화, 답변 근거 span 검증, 데이터셋 편향과 평가자 일치도

이서연 · 기술 및 성장 계획 / SKILLS

RAG 검색 품질 · 하이브리드 검색 · 근거 기반 평가 | RAG / LLM Evaluation Engineer

기술 역량 세부

Python: pandas, scikit-learn 기초, PyMuPDF, pytest, 데이터 전처리

검색: pgvector, BM25, 하이브리드 검색, reranker, 문서 메타데이터

LLM: 프롬프트 평가, structured output, RAG 오류 분석

Backend: FastAPI, PostgreSQL, REST API

Ops: Docker Compose, SQL, Git, 데이터 실험 기록

개발 원칙

- 문서가 검색되었다는 사실과 질문에 대한 정답 근거라는 사실을 구분
- LLM의 평가 결과와 검증 코드의 실패를 하나의 최저점으로 합치지 않음
- 정확한 답이 없을 때는 모른다고 응답하고 부족한 근거를 표시
- 데이터셋 버전과 검색 파라미터를 남겨 실험 재현성 확보

입사 후 기여 계획

초기에는 현업 문서의 형태와 개정 주기를 파악하고 문서 품질 점검 규칙을 만들겠습니다. 이후 업무 질의 평가셋을 구축하고 검색 품질·근거성·응답 속도를 함께 개선해 실제 사용자가 신뢰할 수 있는 RAG를 운영하고 싶습니다.

면접에서 설명할 수 있는 주제

- RAG 데이터가 적은 경우 무작정 문장을 증강하는 것이 위험한 이유
- 하이브리드 검색과 재순위화의 효과를 별도로 측정하는 방법
- 검색된 문서의 시점·소유 회사·접근 권한을 보호하는 방법
- 답변 원문 근거 추출 실패와 내용 부족을 구분하는 평가 설계

자기소개

저는 모델을 잘 사용하는 것뿐 아니라 그 모델이 어떤 자료를 보고 답했는지 설명할 수 있는 서비스를 만들고 싶습니다. 품질 문제를 감으로 판단하기보다 실제 데이터와 오류 유형으로 구분하는 신입 AI 엔지니어가 되겠습니다.